

APLICAÇÃO DE DEEP LEARNING NO RECONHECIMENTO DE LARVAS DE CAMARÃO

William Arcanjo Mendes de Moraes¹; Adriana Takahashi²

Palavras-chave: Carcinicultura. Detectron2. Deep learning.

Introdução

A aquicultura é uma atividade socioeconômica muito importante e a comercialização do produto camarão aumenta a cada ano (ROCHA et al, 2013), sendo o Brasil um representante mundial da produção e comercialização do crustáceo. A pesca predatória do camarão no mar é uma atividade de custo elevado, tornando mais atrativa a produção deste crustáceo em cativeiros (NATORI et al., 2011). O sucesso da carcinicultura depende, minimamente, de: inovações tecnológicas, domínio de técnicas de manejo da carcinicultura, domínio da larvicultura, condições do mercado financeiro nacional e mundial e incentivos de políticas públicas. As indústrias brasileiras começaram a ingressar nas novas gerações de sistemas de cultivo da carcinicultura, com o uso de inovações tecnológicas e protocolos de cultivo com biossegurança, buscando o aumento da produtividade e a qualidade do produto (MANSO, 2006). Considerando a importância socioeconômica dessa atividade produtiva na economia do país, e também contribuir para o desenvolvimento tecnológico que auxilia o fortalecimento da carcinicultura brasileira em escala industrial, visto que, as técnicas de manejo e contagem de larvas de camarão são realizadas manualmente (SENAR, 2016) ou utilizam equipamentos de custo muito elevado (XPERTSEA), este projeto de pesquisa desenvolveu um sistema para reconhecimento e detecção de larvas de camarões utilizando deep learning, buscando o auxílio no controle e na qualidade das larvas em suas diferentes fases do ciclo de vida.

Neste trabalho é apresentado um sistema para auxiliar no controle da larvicultura, melhorando o processo de contagem de larvas de camarão na fase pós larva (PL). O sistema consiste na aquisição das imagens contendo as PLs e sua contagem automática utilizando uma rede neural convolucional (CNN), otimizando o tempo, diminuindo a invasão no manejo e evitando a aquisição de equipamentos de custos elevados.

Metodologia

Os procedimentos metodológicos adotados para o desenvolvimento do sistema de detecção e contagem de PLs de camarões foram separados nas seguintes etapas:

Levantamento de requisitos: buscando técnicas existentes no processo de contagem de larvas de camarão (SENAR, 2016; XPERTSEA), bem como, a fundamentação teórica relacionada ao tema da pesquisa: carcinicultura (DABADÉ, 2015; NATORI et al, 2011; ORMOND et al., 2004; SIQUEIRA, 2017) e larvicultura (LIMA, 2007; SENAR, 2016; THOMAZ et al., 2004). Os requisitos de software e hardware necessários para o desenvolvimento deste projeto foram detalhados na etapa de implementação.

Modelagem do sistema: dividida em duas etapas: aquisição de imagens contendo as PLs e detecção e contagem automática das PLs.

Aquisição da imagem: Sistema para geração de imagens contendo PLs de camarões de tamanhos configuráveis e posições aleatórias, assim como a densidade de PLs por imagem. O sistema de aquisição das imagens contendo PLs foi necessário devido a inviabilidade em adquirir lotes de larvas de camarão durante a execução do projeto, pois, além do custo, o

¹ Estudante do curso de Ciência da Computação do Departamento de Computação da Universidade do Estado do Rio Grande do Norte; email: williammoraes@alu.uern.br.

² Professora do Departamento de Computação do Campus de Natal da Universidade do Estado do Rio Grande do Norte, Participante do Grupo de Pesquisa de Inteligência Computacional; email: adrianatakahashi@uern.br.

produto é frágil e perecível. Para a geração das imagens foram considerados dois parâmetros iniciais: a qualidade e o tamanho das imagens, e posteriormente, a densidade e a configuração da PL (estágio da PL em seu ciclo de vida) (KARTHIK et al, 2015). O sistema de aquisição de imagens foi projetado para simular a aquisição de imagens reais.

Detecção e contagem automática: Para detecção e contagem das PLs foi utilizado técnicas de *deep learning* por serem conceitualmente flexíveis e robustas (JIAO et al, 2019; KHAN et al, 2020). Técnicas de detecção de objetos e segmentação de instâncias foram escolhidas para detecção das PLs, pois detectam múltiplas categorias, poses, saliências, localização, dentre outros atributos de objetos na imagem bem como a complexidade e a precisão da detecção (LIU et al, 2020; YANG et al, 2020; ZHAO et al, 2019). Dentre os detectores de objetos, foi escolhido o Detectron2 (WU et al, 2019) devido sua alta precisão da localização e reconhecimento de objetos e tempo de treinamento comparado com outras CNNs da mesma categoria (GIRSHICK, 2015; HE et al, 2018; LIN et al, 2017). O Detectron2 é o sucessor do Detectron e Mask R-CNN, desenvolvido pela Facebook AI Research (FAIR), é uma CNN baseada em regiões e segmentação de instâncias para detecção de objetos, que classifica, localiza e diferencia objetos individuais por uma caixa delimitadora (*bounding box* - bbox) em paralelo com uma máscara de segmentação de instâncias (segm) (WU et al, 2019). Permite diferentes configurações, Model Zoo (MODELZOO, 2020), pré treinadas entre os principais datasets de aprendizagem de máquina, e.g., MS COCO (LIN et al, 2015), Imagenet (DENG et al, 2009) e Cityscapes (CORDTS, 2015). A segmentação de instâncias permite rotular instâncias diferentes entre o mesmo tipo de objetos, isso se torna interessante na detecção das PLs, pois, em uma imagem pode conter diversas larvas sobrepostas, sendo necessário uma técnica que considere essa complexidade. Os modelos pré-treinados Model Zoo utilizados, de segmentação de instâncias, foram: Mask R-CNN R50-FPN e Mask R-CNN R101-FPN, considerando os menores tempos de treinamento descritos no Model Zoo.

Implementação: codificação do sistema de aquisição de imagens e instalação e configuração do Detectron2 para detecção das PLs. Foram necessários os softwares: CUDA 10.1, PyTorch 1.8.1, Python 3.8 e OpenCV 4.2.0; os hardwares: placa de vídeo NVIDIA RTX 2070, processador intel core i7-8700, 32Gb de memória RAM e HD (mínimo 130 gb para armazenamento dos dados do treinamento); e os sistemas operacionais: Linux e MacOS. Para as anotações gráficas das PLs nas imagens para construção do dataset foi utilizado Labelme (WAKA, 2016) e convertidos no formato COCO.

Teste: etapa dividida em treinamento, validação e teste. Primeiro foi construído o dataset, com 330 imagens contendo PLs, onde, metade do dataset as anotações foram feitas manualmente e a outra metade automaticamente. Para análise do dataset foi utilizando duas formas: validação cruzada k-fold e holdout (KOHAVI, 1995), e comparados os resultados utilizando as métricas: *Mean Average Precision* (mAP), *Mean Recall* (mAR), e *F1-score* (F_1) (PADILLA, NETTO, SILVA, 2020). Para o treinamento e validação foram analisados o Erro total de treinamento (loss), mAP, mAR e F_1 , tanto para bbox quanto para segm. O teste foi analisado a proporção de acertos das instâncias segmentadas.

Resultados e discussão

Para a validação dos resultados foram feitas três análises comparativas: a primeira análise foi comparar os datasets com anotações automáticas e manuais. Cada dataset possui 165 imagens com 3683 larvas. As métricas de avaliação para 50k épocas, do dataset com anotações automáticas, para o bbox foram: mAP (85.2%), mAR (87.9%) e F_1 (86.5%); e para a segm foram: mAP (70.6%), mAR (73.3%) e F_1 (71.9%). Naturalmente, as métricas para o bbox é maior comparado com a segm, pois não necessita análise dos pixels do conjunto da máscara. Os resultados das métricas do dataset com anotações automáticas foram melhores comparados com o outro, devido a padronização das anotações.

Outra análise da reamostragem foi considerar quatro configurações do dataset:

teste1, teste2 e teste3 utilizando validação cruzada k-fold ($k = 3$) e teste4 utilizando validação cruzada holdout (60% treinamento, 20% validação e 20% teste). Considerando a média dos quatro datasets, no treinamento de 15k épocas, obteve-se: a média do erro de treinamento, loss (0.295); as médias das métricas para bbox: mAP (87.7%), mAR (91.1%) e F_1 (89.3%); as médias das métricas para segm: mAP (61.9%), mAR (65.7%) e F_1 (63.7%).

Com base nas análises anteriores, foram comparados dois modelos Model Zoo para segmentação de instância COCO com Mask R-CNN: R50-FPN (3x) e R101-FPN (3x). O dataset de treinamento possui 198 imagens com 4172 larvas, o dataset de validação possui 66 imagens com 1631 larvas e o dataset de teste possui 66 imagens com 1563 larvas. A Tabela 1 mostra os resultados com o treinamento e validação para 50k épocas.

Tabela 1: bbox

	Treinamento			Validação		
	mAP	mAR	F_1	mAP	mAR	F_1
R50-FPN	92.6%	84.4%	88.3%	84.2%	86.8%	85.5%
R101-FPN	94.2%	95.7%	94.9%	82.7%	86.2%	84.4%

Para o treinamento, o modelo R50-FPN obteve as métricas para segm: mAP (66.6%), mAR (70.2%) e F_1 (68.4%) e o modelo R101-FPN: mAP (66.2%), mAR (70.4%) e F_1 (68.2%). Os erros médios de treinamento foram: R50-FPN (0.243) e R101-FPN (0.195). Para o conjunto de teste as predições foram: R50-FPN (97.6%) e R101-FPN (97.2%).

Conclusão

Técnicas de contagem de larvas automatizadas podem auxiliar na qualidade durante o processo de produção e manejo de larvas de camarão, considerando o tempo, a precisão e os custos. Neste trabalho apresentou-se um sistema de detecção e contagem de larvas de camarão considerando a densidade de larvas de camarão por imagem e o seu ciclo larval. Os resultados obtidos mostram uma precisão média, para o bbox, de 93.4% e para o segm 66.4% na contagem de PLs de camarão no treinamento (modelo R50-FPN e R101-FPN). Os resultados dos testes foram obtidos com uma precisão média de detecção e contagem de larvas de camarão de 97.4% de acertos. Considerando que o processo de contagem de PLs de camarão manual é dispendioso, demorado e desgastante, com uso de placas de petri, beakers e pipetas, e a existência de uma ferramenta de contagem de organismos aquáticos tem um custo muito elevado, a ferramenta desenvolvida neste trabalho demonstra bons resultados iniciais, contudo, esses resultados podem ser melhor trabalhados considerando data augmentation, iluminação, condições da água (ruídos), entre outras variáveis, de modo aumentar a capacidade de generalização mantendo ou melhorando a precisão de detecção e contagem de larvas corretas.

Agradecimentos

Agradecimentos ao Departamento de Computação (grupo de pesquisa GIC) da Universidade do Estado do Rio Grande do Norte pelo apoio tecnológico, estrutural e científico.

Referências

- CORDTS, M. et al. The Cityscapes Dataset. CVPR Workshop on The Future of Datasets in Vision, 2015.
- DABADÉ, D. S. Shrimp quality and safety management along the supply chain in Benin. PhD thesis, Wageningen University, Wageningen, NL, 2015.
- DENG, J. et al. ImageNet: A Large-Scale Hierarchical Image Database. IEEE Computer Vision and Pattern Recognition, 2009.
- GIRSHICK, R. Fast R-CNN. Computer Vision and Pattern Recognition, 2015. <https://arxiv.org/abs/1504.08083v2>.
- HE, K. et al. Mask R-CNN. Computer Vision and Pattern Recognition, 2018. <https://arxiv.org/abs/1703.06870>.

JIAO, L. et al. A Survey of Deep Learning-based Object Detection. *IEEE Access*, v. 7, 128837-128868, 2019. <https://doi.org/10.1109/access.2019.2939201>.

KARTHIK, R et al. Attenuation of Negative Impacts by Micro Algae and Enriched *Artemia Salina* on *Penaeus Monodon* and *Litopenaeus Vannamei* Larval Culture. *Journal of Aquaculture Research & Development*, v. 6: 10, 2015.

KHAN, A. et al. A survey of the recent architectures of deep convolutional neural networks. *Artificial Intelligence Review*, 53(8), 5455-5516, 2020.

KOHAVI, R. A study of cross-validation and bootstrap for accuracy estimation and model selection. *International joint Conference on artificial intelligence*, v. 14, p. 1137–1145, 1995.

LIMA, L. C. M. Sobrevivência e crescimento larval do camarão marinho *Litopenaeus Vannamei* alimentado com o copépodo bentônico *tisbe biminensis*. Dissertação (Mestrado em Biologia Animal) - Curso de Pós-Graduação em Biologia Animal, Universidade Federal de Pernambuco, Recife, 2007.

LIN, T. et al. Feature Pyramid Networks for Object Detection. *Computer Vision and Pattern Recognition*, 2017. <https://arxiv.org/abs/1612.03144>.

LIN, T. et al. Microsoft COCO: Common Objects in Context. *Computer Vision and Pattern Recognition*, 2015. <https://arxiv.org/abs/1405.0312>.

LIU, L. et al. Deep Learning for Generic Object Detection: A Survey. *International Journal of Computer Vision*, v. 8, p. 261–318, 2020.

MANSO, P. R. J. Produção em cativeiro de larvas de camarão marinho *Litopenaeus vannamei*: influência do campo magnético sobre a metamorfose e sobrevivência larval. 2006. Dissertação (Mestrado em Engenharia de Produção) em Engenharia de Produção, Universidade Federal de Santa Catarina, Florianópolis, 2006.

MODELZOO. Detectron2 Model Zoo and Baselines. Facebook AI Research (FAIR), 2020. https://github.com/facebookresearch/detectron2/blob/master/MODEL_ZOO.md

NATORI, M. M. et al. Desenvolvimento da carcinicultura marinha no Brasil e no mundo: avanços tecnológicos e desafios. *Revista Informações econômicas*, Instituto de Economia Agrícola (IEA), São Paulo, 2011.

ORMOND, J. G. P. et al. A carcinicultura brasileira. *Banco Nacional de Desenvolvimento Econômico e Social - BNDES Setorial*, Rio de Janeiro, n. 19, p. 91-118, 2004.

PADILLA, R.; NETTO, S. L.; SILVA, E. A. B. A survey on Performance Metrics for Object-Detection Algorithms. *Proceedings of the IWSSIP*, 2020.

ROCHA, C. M. C. et al. Avanços na pesquisa e no desenvolvimento da aquicultura brasileira. *Pesquisa Agropecuária Brasileira*, Brasília, v. 48, n. 8, 2013.

SENAR. Larvicultura de camarão marinho: do náuplio a pós-larva. *Serviço Nacional de Aprendizagem Rural - Coleção SENAR* - 166, Brasília, 2016.

SIQUEIRA, T. V. Aquicultura: a nova fronteira para aumentar a produção mundial de alimentos de forma sustentável. *Boletim Regional, Urbano e Ambiental*, Instituto de Pesquisa Econômica Aplicada (Ipea), v. 17, p. 53-60, 2017.

THOMAZ, L. A. et al. Desempenho larval do camarão-d'água-doce (*Macrobrachium rosenbergii* De Man, 1879) submetido a diferentes regimes alimentares. *Revista Brasileira de Zootecnia*, v. 33, n. 6, p. 1934-1941, 2004.

XPRTSEA. XpertSea. Disponível em: <<https://xpertsea.com/company/about-us>>. Acessado em: 05 de março de 2021.

WAKA, K. Labelme: Image Polygonal Annotation with Python. (2016).

WU, Y. et al. Detectron2. Facebook AI Research (FAIR), 2019.

YANG, Z. et al. Instance Segmentation Method Based on Improved Mask R-CNN for the Stacked Electronic Components. *Electronics*, v. 9, 886, 2020.

ZHAO, Z. et al. Object Detection With Deep Learning: A Review. *IEEE Transactions on Neural Networks and Learning Systems*, v. 30: 11, p. 3212 - 3232, 2019.